

# Mixture-of-Memory: 用固定大小记忆缓冲

## 压缩长上下文的 LLM 适配器

——一次由大模型 Agent 自主驱动的研发实践

课程：大模型驱动的软件开发（2026 春季学期）成果报告

姓名：刘涵祚 班级：计科 41

源码：<https://github.com/liuhanzuo/Mixture-of-Memory>

### 摘要

本工作研究如何把超长上下文压缩进一个固定大小的记忆缓冲（memory bank），使 Llama-3-8B 在有界 KV 预算下处理长序列。我们提出的 mem\_space 适配器与混合专家（MoE）高度同构——可视为 **Mixture-of-Memory (MoM)**： $N$  个记忆 slot 即“专家”，一个轻量 selector 对每个 chunk 做 top- $k$  路由，写入只更新被选中的 top- $k$  slot（稀疏更新），读出则对全部  $N$  个 slot 做独立 softmax。我们诊断出该架构的核心瓶颈是“写得进、读不准”（纯记忆读出 W0 仅 10-30，而开卷上限 50-60），并系统比较了四类干预：token-mass 读出加权、self-study 蒸馏、长度课程、以及二者叠加。关键发现是弱 mass（强度  $\approx 0.5$ ）与蒸馏在长程（16k/32k）上首次产生协同，超过任一单独方法；mass 过强反而干扰。LongBench 真实长文档评测进一步把能力缺失定位到“超长叙事连贯”与“细粒度抽取”。尤为重要的是，整个研发过程——集群巡检、实验调度、代码实现、缺陷排查与质量护栏——由大模型 Agent 闭环自主驱动，本报告同时是这一研发范式的实证。

## 1 引言：由大模型 Agent 自主驱动的研发

本课题的特别之处在于：从实验设计、五节点 GPU 集群调度、代码实现、到缺陷排查与结论分析，几乎全程由大模型 Agent 以闭环方式自主驱动，人类仅在关键方向上给出判断。具体工作流包括：

- Heartbeat 主动巡检闭环**：每 30 分钟一次定时巡检，真查 5 节点（本机 + 3×H20 + 1×B200）GPU 占用，对在跑的训练/评测做健康检查（step 递增、nf=0、无 NCCL/OOM），空闲节点立即补任务、不留空转。
- 多 Agent 并行协作**：研究调研、设计文档、代码实现、根因排查由多个子 Agent 分工并行，主 Agent 综合结论。
- 双重验证原则**：仅看 GPU busy 快照会误判——busy=8/8 可能是 NCCL teardown 僵死、proc=0 但 busy=8/8 是残留显存、4/8 可能是 eval 切任务的瞬时空隙；必须交叉验证进程状态与产物。
- 踩坑 → 护栏沉淀**：每个静默失效（数据饥饿、缓存失配、显存竞争）都被转化为代码级 fail-fast 护栏（见第 4 节）。

这种范式的价值在于：它能在长达数十小时的实验中保持高 GPU 利用率与实验连续性，同时把人类从重复的运维与监控中解放出来，只聚焦科学判断。下文先介绍方法（第 2 节），再展开核心科学问题与攻坚（第 3 节），最后总结工程护栏（第 4 节）与结论（第 5 节）。

## 2 方法：Mixture-of-Memory (MoM)

### 2.1 动机：有界 KV 预算下的长上下文

标准 Transformer 的 KV cache 随序列长度线性增长，超长上下文下显存不可承受。我们的思路是把任意长的上下文压缩进一个固定大小 ( $N$  个 slot) 的记忆缓冲：输入流按 `chunk_size=512` 切块，逐块流式写入记忆；回答时只从记忆读出，KV 预算与序列长度无关。

### 2.2 核心类比：MoM $\approx$ MoE (top- $k$ 路由那一维的并行)

`mem_space` 适配器与混合专家 (MoE) 在结构上高度同构，这是我们理解与设计该架构的主线：

- $N$  个 memory slot  $\approx N$  个“专家”。一个所有 Transformer 层共享的 MemoryBank (每样本一份) 持有这些 slot。
- Selector  $\approx$  门控网络：对每个 chunk 给全部  $N$  个 slot 打分，选出 top- $k=16$  个 slot 参与本步——这正是 MoE 的稀疏门控。
- 写入 (Write) = 仅对 top- $k$  选中的 slot 做门控 delta-rule 更新 (稀疏更新，每步至多触碰  $k$  个 slot)，对应 MoE 只激活 top- $k$  专家。
- 读出 (Read) = 专用 MemoryCrossAttentionRead，对全部  $N$  个 slot (含一个 null/sink) 做独立 softmax。
- 读写路径刻意解耦：写是 top- $k$  稀疏，读是 all- $N$  稠密——这点与标准 MoE “激活即输出”不同，也埋下了后文的核心瓶颈。

### 2.3 架构细节

- Chunk 流式写入：context chunk 在 `no_grad` 下逐块写入并 detach，目标 chunk 带梯度——逼记忆通道真正承载长程信息。
- Dual-gate delta-rule 写回：输入门 + 遗忘门控制写入，可选残差 delta-rule 更新 (按输入门加权)。
- L3 summary：共享的 L3 交叉注意力路径产出  $K=64$  个 summary token，承载长程信息，是长程主力。
- 代码：`src/memory/mem_space/` (config / layer / selector / memory\_bank / l3\_summary)。  
架构迭代见 `versions/`。

## 3 核心问题与攻坚：readout 瓶颈

### 3.1 诊断：“写得进，读不准”

我们用 BABILong (qa1/qa2/qa5, 0k-32k) 评测，并区分两种读出口径：开卷 SWA (query 段局部 attention 直接看原始 KV) 与闭卷 W0 (纯记忆读出，`--swa_eval_chunks 0`)。关键观察：开卷 SWA 能到 50-60 分，说明信息确实进了记忆；但纯记忆读出 W0 只有 10-30，长程 32k 跌到约 6。即——信息写得进，却读不准。瓶颈在读出机制，而非存储。

## 3.2 四类杠杆

- **token-mass 读出加权**: 让 slot 按其浓缩的真 token 数在 readout softmax 前加  $\log p(\text{mass})$  偏置 (高信息量 slot 更易被读到)。
- **self-study 蒸馏**: teacher = 冻结 backbone 看完整上下文 (开卷), student = 记忆读出 (闭卷), 用 logits-KL + hidden-cosine 让闭卷逼近开卷。
- **长度课程 (curriculum)**: 训练序列长度  $4K \rightarrow 8K \rightarrow 16K \rightarrow 32K$  渐进 (仅作用于 T2 合成检索流, dolmino 锁定避免数据饥饿)。
- **叠加**: token-mass  $\times$  蒸馏的不同强度组合。

## 3.3 关键结果




图 1: 四类杠杆在 BABILong qa5 (chunk512, W0) 各长度上的对比。

(1) mass 与蒸馏各自有效: mass 在中短程把 qa5 翻倍 (1k 31 $\rightarrow$ 58) 且 seed 鲁棒; 蒸馏可复现、8k 处最强 (15)。(2) 长度课程救回了“直训 32k 退化”, 但未突破中程天花板。(3) **【最重要】**: 弱 mass (coef  $\approx 0.5$ ) + 蒸馏在长程产生协同——下图显示随 mass 强度呈倒 U, 峰值 coef  $\approx 0.5$  时 16k=13、32k=9, 首次超过所有单独方法; mass 过强 (coef=2.0) 则与蒸馏目标冲突、长程崩到 5-6。




图 2：弱叠加 coef 精扫：长程 qa5 随 mass 强度呈倒 U，峰值在 coef $\approx$ 0.5。

(4) 长训退化：最优配置在约 500 步即收敛，继续训到 1000 步长程反而下降（32k 9 $\rightarrow$ 6）——“早停”是甜点，不应盲目加训练量。

### 3.4 LongBench 真实长文档：能力缺失定位




图 3：LongBench 6 数据集：记忆模型 W0（F1）相对 base 开卷基线的保留率。

我们首次在真实长文档 QA（LongBench 6 数据集）上拿到记忆模型的 W0 分（此前因显存竞争与格式问题屡次静默失败）。对照 base 模型开卷基线，能力缺失高度集中：narrativeqa（超长叙事）几乎全失效（16.0 $\rightarrow$ 2.6，仅保留 16%），qasper（科学论文细节）保留 38%；而多跳检索类（2wikimqa/hotpotqa）保留 66-75% 相对最好——恰是合成检索训练强化的“跨片段关联”能力。这把下一步要攻的短板明确指向“超长单一文档的连贯保持”与“细粒度信息保真”，而非关联检索。

## 4 工程实践与质量护栏

大模型驱动的高强度实验会遇到大量“看着在跑、其实没效果”的静默失效。本工作把每次踩坑都沉淀为代码级护栏，形成质量闭环——这是“大模型驱动软件开发”能否可靠的关键：

- **数据饥饿** → **启动即报错**：dolmino 单文档上限 4096 token，当  $(n\_ctx + 1) \times chunk\_size$  超限时 loader 零产出、DDP 第一步静默死锁。修复：零产出 epoch 直接 raise，并把长度课程解耦到 T2 流（dolmino 锁  $n\_ctx=3$ ）。
- **蒸馏缓存失配** → **指纹断言 + 命中率 fail-fast**：teacher 缓存按位置索引，跨盘数据集行序不同 / 文件漏同步会导致 100% cache miss、蒸馏静默失效。修复：缓存记录数据集 fingerprint，训练启动断言一致；step50 命中率为 0 即 raise。
- **NCCL teardown 僵死**：训练逻辑完成却卡在 teardown，busy=8/8 假象占卡数小时。巡检需交叉验证进程状态与 final ckpt。
- **显存竞争 OOM**：启动训练前必须查 nvidia-smi 真实显存（不能只看 proc 数），避免与残留进程争抢。
- **跨盘一致性**：三个独立物理盘(diskA/diskB/B200-wzc1)，代码改动需完整 rsync(含 build/launch/src 全部文件)。
- **LongBench chat\_template**：base 模型无 chat\_template，脚本硬编码 --use\_chat\_template 致全 worker 首样本崩溃；改为默认关闭。

这些护栏的共同主题是：把静默失效转化为快速、显式的失败，让 Agent 在下一个巡检周期就能发现并自愈，而不是浪费数小时算力。

## 5 结论与展望

- MoM 的 MoE 式 top- $k$  路由能在有界 KV 下承载长上下文，但读写解耦带来“读不准”的核心瓶颈。
- 机制侧杠杆（mass、蒸馏）优于训练侧（容量/长度/课程）；弱 mass+ 蒸馏的组合在长程首次超过单独方法。
- 长程 32k 仍是共同天花板（6→9），未被根本突破；真实长文档上缺失集中于超长叙事与细粒度抽取。
- 展望：沿最优弱叠加配置 + 针对“连贯/细粒度”的新机制，配合 LongBench 持续验证。

方法论层面，本工作验证了大模型 Agent 可以自主驱动一个真实的多节点 ML 研究项目——从调到排错到结论——并通过护栏沉淀保证工程可靠性。

## A 完整 W0 对照表 (BABILong qa5, chunk512, 0–32k)

| 配置                     | 0k | 1k | 2k | 4k | 8k | 16k       | 32k      |
|------------------------|----|----|----|----|----|-----------|----------|
| baseline (T2_chunk512) | 70 | 31 | 53 | 22 | 13 | 8         | 6        |
| mass coef0.5           | 73 | 49 | 40 | 25 | 10 | 12        | 9        |
| mass coef2.0           | 78 | 58 | 48 | 28 | 10 | 12        | 7        |
| mass coef2 (seed1234)  | 63 | 58 | 46 | 26 | 12 | 10        | 8        |
| 蒸馏 A+B                 | 70 | 59 | 45 | 25 | 15 | 11        | 8        |
| 叠加 coef0.5+ 蒸馏         | 70 | 49 | 44 | 25 | 14 | <b>13</b> | <b>9</b> |
| 叠加 coef0.7+ 蒸馏         | 69 | 57 | 36 | 26 | 11 | 10        | 8        |
| 叠加 coef2.0+ 蒸馏         | 71 | 50 | 33 | 22 | 10 | 6         | 5        |

## B 弱叠加 coef 精扫 (长程 qa5)

| coef | 8k | 16k       | 32k      |
|------|----|-----------|----------|
| 0.3  | 14 | 11        | 8        |
| 0.5  | 14 | <b>13</b> | <b>9</b> |
| 0.7  | 11 | 10        | 8        |
| 2.0  | 10 | 6         | 5        |

## C LongBench W0 (F1) vs base 开卷基线

| 数据集             | mem W0      | base 开卷     | 保留率        |
|-----------------|-------------|-------------|------------|
| narrativeqa     | 2.6         | 16.0        | 16%        |
| qasper          | 5.2         | 13.9        | 38%        |
| musique         | 3.5         | 7.0         | 50%        |
| multifieldqa_en | 12.3        | 24.9        | 49%        |
| hotpotqa        | 6.5         | 9.8         | 66%        |
| 2wikimqa        | 9.2         | 12.2        | 75%        |
| 平均              | <b>6.56</b> | <b>14.0</b> | <b>47%</b> |

## D 关键代码与脚本

- 架构: `src/memory/mem_space/{config,layer,selector,memory_bank,l3_summary}.py`
- token-mass: `--use_readout_mass_bias --readout_mass_coef` (commit 79ad265)
- self-study 蒸馏: `scripts/build_distill_cache.py + scripts/launch_distill_chunk512_AB.sh` (commit 19477fb / 8ea2969)
- 长度课程解耦 + 数据饥饿护栏: `--t2_curriculum` (commit dadc19f / 2c22d80)
- 缓存指纹 + 命中率 fail-fast: commit 0cf2c23 / 438b674
- 设计文档: `versions/v21_selfstudy_distillation.md`
- 阶段报告: `status/READOUT_ATTACK_STAGING_REPORT.md`
- 源码仓库: <https://github.com/liuhanzuo/Mixture-of-Memory>